Ministério da Educação
Universidade Federal do Agreste de Pernambuco
Bacharelado em Ciência da Computação

Disciplina: Laboratório de Ciência de Dados

2026.2

Prof. Ryan Azevedo

PROJETO 1

O projeto deve ser desenvolvido em **Python**:

1. O relatório de análise deve ser **apresentado por meio de um sistema web** desenvolvido em ***Python*** (sugestão: ***Flask***; o grupo pode usar outro framework, desde que justifique). O sistema deve funcionar como o **relatório do projeto**, exibindo, para cada item do enunciado:

    - **(a) os resultados** — tabelas e gráficos;
    - **(b) a interpretação textual** — a análise crítica dos resultados.

Exigências mínimas do sistema:

- Deve exibir, no mínimo: (i) o dicionário de dados; (ii) as medidas descritivas por variável e por time; (iii) os gráficos produzidos (Boxplot e gráfico de barras comparativo); (iv) a seção de síntese/interpretação; e (v) a discussão dos métodos de qualidade dos dados (*missing*, *outliers*, inconsistências).
- Deve ser **navegável e interativo**: o usuário deve poder selecionar o time e/ou a variável e ver os resultados correspondentes atualizados.
- **Todos os gráficos** devem ter título, eixos rotulados, unidades e legendas.
- **Todas as tabelas** devem ser padronizadas (mesmas casas decimais, mesmas unidades).
- O sistema deve estar **hospedado e acessível por link público** no momento da avaliação. Se a hospedagem gratuita sair do ar, o grupo é responsável por restabelecê-la. Alternativa aceita: instruções claras de execução local no README.md (com requirements.txt e comando único).

Observação: o sistema **substitui o relatório em PDF/notebook**. Não é necessário entregar um documento separado — o conteúdo analítico deve estar **dentro do sistema web**, organizado por seções correspondentes aos itens do enunciado.

Entregar via Classroom:

- **Código-fonte** enviado **pelo Google Classroom da disciplina**, em arquivo .zip ou link de repositório (*GitHub*/*GitLab*).
- **Link da aplicação** informado no campo de submissão do *Classroom*.
- **Critérios de avaliação**: ver rubrica em anexo. (Ou: "a rubrica será apresentada em sala".)

Observação sobre decisões metodológicas: itens não especificados neste enunciado devem ser decididos pelo grupo e **justificados no relatório**. Dúvidas devem ser levadas ao professor.

DESENVOLVIMENTO

Apresente:

- O número de linhas e colunas, o nome das colunas e o que elas representam dentro do contexto (Cliente? Vendedor, Jogador?). Crie um Apêndice/Dicionário e informe o que significa cada coluna da Base.

- Os tipos de dados de cada coluna? Quais são numéricas, categóricas, datas, texto, binárias? Apresente para o usuários os tipos de dados de cada coluna. Para um gestor talvez não seja necessário, mas para a equipe de desenvolvimento possivelmente é importante.

- Tamanho da Base/Dataset, como tratar os campos do tipo Data? Na base, você deve tratar o campo data.

- Altere o nome das colunas com novos nomes intuitivos.

- Algumas colunas estão como categóricas e precisam ser numéricas, trate isso e informe como tratou. Ex; W e L. Verifique se a base possui algum campo do tipo Data e se o mesmo necessita de algum tratamento.

- Exclua colunas que não servem para previsões usando modelos de aprendizado de máquina e aprendizado profundo. (Os grupos devem entender do contexto da base de dados).

- Verifique a existência de **Valores especiais**: zeros, negativos, duplicados, valores fora de domínio (ex.: idade = 999).

- Qual a quantidade de campos com valores ausentes por coluna? Explique os mecanismos **MCAR**, **MAR** e **MNAR** (mecanismos clássicos que descrevem por que os dados estão faltando em um conjunto de dados)

    - Como e por que utilizar os seguintes testes:

        - Teste de *Little* (*Little's* MCAR *test*), teste de *Jamshidian-Jala*
        - Teste de *Listing* e *Schlitgen* (LS), Regressão Logística de *Fairclough*.

- Para cada coluna qual a quantidade de campos com valores inconsistentes ou *outliers*?

    - Você deve implementar e explicar a teoria dos métodos abaixo:

        - *Z-score* usando o desvio padrão da média ou outro limiar, pode utilizar IQR (Intervalo Interquartil) /Boxplot e verificar os extremos.
        - Teste de *Grubbs*
        - ECOD (*Empirical Cumulative Distribution-based Outlier Detection*)
        - K-NN (*K-Nearest Neighbors*) para anomalias
        - DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*)
        - LOF (*Local Outlier Factor*)
        - Você pode utilizar métodos de Machine Learning para dados de alta dimensionalidade e padrões complexos, por enquanto não utilizaremos.

Estatística Descritiva: (Por enquanto Análise Univariada)

Apresente:

- As medidas de tendência central para: Pontos, Rebotes, Assistências, STL, BLK, PF e FG3M, dos times selecionados para o seu grupo de trabalho:

    - Média, Mediana e Moda
    - Outliers (Quantos e quais são)
    - Menos valor, Maior Valor, Amplitude, Desvio Padrão e Variância
    - Quartis (Q1, Q3)
    - Apresente um gráfico Boxplot com as medidas encontradas para cada variável pedida, o gráfico deve conter Outliers Superiores, Limite Superior, Q3, Média, Mediana, Moda, Q1, Limite Inferior e Outliers Inferiores.
    - Construa um gráfico de barras que possibilite comparar os dados pedidos para os times do seu grupo, onde o z-score poderia entrar?

- Verificar a Assimetria (*skewness*) → Para cada uma das variáveis (Pontos, Rebotes, Assistências, STL, BLK, PF e FG3M) e para cada time do grupo:

    - Calcule o coeficiente de assimetria e informe explicitamente qual fórmula/implementação utilizou (ex.: coeficiente de momento de *Pearson*, coeficiente ajustado de *Fisher-Pearson* ou coeficiente de *Bowley*). Justifique a escolha.

    - Classifique a distribuição quanto à direção (simétrica, assimétrica à direita/positiva ou à esquerda/negativa), com base no sinal do coeficiente.

- Classifique a intensidade da assimetria (aproximadamente simétrica, moderada ou forte), informando o critério adotado (ex.: $|g1| < 0{,}5$; $0{,}5 \leq |g1| < 1$; $|g1| \geq 1$ — ou outro critério justificado).

- Confirme visualmente a assimetria com um histograma com curva de densidade (KDE) sobreposto e com o Boxplot já construído. Comente se o coeficiente e os gráficos contam a mesma história; se houver divergência, discuta o motivo.

- Compare os resultados entre variáveis e entre times. Destaque quais variáveis são mais assimétricas e se o padrão se repete nos times do grupo.

- Discuta a implicação prática da assimetria encontrada: nessa variável, a média ou a mediana representa melhor o valor típico? Há indício de que transformações (ex.: log) ou métodos robustos seriam apropriados em análises posteriores

- Coeficiente de Variação (CV) → Para cada uma das variáveis (Pontos, Rebotes, Assistências, STL, BLK, PF e FG3M) e para cada time do grupo:

    - Calcule o CV e informe explicitamente a fórmula utilizada, incluindo se o desvio padrão é amostral (n – 1) ou populacional, e se o resultado é apresentado em fração ou em percentual. Mantenha a mesma convenção adotada nas demais medidas do projeto.

    - Verifique a condição de validade do CV para cada variável: a variável é de razão? A média é positiva e suficientemente distante de zero? Se a média for muito pequena (caso típico de BLK e STL), explique por que o CV fica inflado e deve ser interpretado com cautela.

    - Interprete o valor obtido: o que um CV alto ou baixo significa, em termos práticos, para aquela estatística do time (ex.: “o time tem pontuação muito irregular de um jogo para outro” vs. “o time é consistente”).

    - Use o CV para comparar dispersão entre variáveis de escalas diferentes. Destaque quais variáveis são relativamente mais dispersas e quais são mais estáveis, justificando por que o desvio padrão bruto não permitiria essa comparação (escalas distintas) e o CV permite (medida adimensional).

    - Compare os times do grupo quanto à homogeneidade/regularidade: qual time é o mais consistente e qual é o mais irregular em cada variável? O padrão se mantém entre variáveis ou muda?

    - Confronte o CV com o desvio padrão e com a assimetria já calculada. Em variáveis com assimetria forte, discuta se o CV (baseado na média e no desvio) é uma medida adequada ou se uma alternativa robusta (ex.: coeficiente de variação baseado na mediana, ou razão entre IQR e mediana) seria mais apropriada.

- Apresente um quadro-resumo (linhas = variáveis, colunas = times, células = CV) para facilitar a comparação, e comente os destaques.

- Intervalo Interquartil (IQR) → Para cada uma das variáveis (Pontos, Rebotes, Assistências, STL, BLK, PF e FG3M) e para cada time do grupo:

  - Calcule o IQR como IQR = Q3 − Q1 e informe explicitamente qual método de cálculo dos quartis foi utilizado (ex.: método de *Tukey*, de *Moore & McCabe*, ou interpolação linear, padrão de *numpy*/pandas). Mantenha o mesmo método adotado no item de quartis e no Boxplot, para garantir consistência.

  - Apresente Q1, Q3 e IQR lado a lado em uma tabela, por variável e por time, para deixar claro de onde o IQR vem.

  - Interprete o IQR em termos práticos: o que um IQR alto ou baixo significa para aquela estatística do time? (ex.: "50% central dos jogos do time ficou dentro de uma faixa de X pontos", o IQR é a largura da faixa central que contém 50% das observações).

  - Compare o IQR com a amplitude (já calculada) e com o desvio padrão (já calculado):

    - Mostre em quais variáveis a amplitude é muito maior que o IQR e explique por que isso acontece (a amplitude é sensível a outliers; o IQR não).

    - Mostre em quais variáveis o desvio padrão é inflado por valores extremos, enquanto o IQR permanece estável, evidência de que o IQR é uma medida robusta.

  - Use o IQR para justificar a regra de detecção de outliers adotada no item anterior: deixe explícito se usou 1,5×IQR ou 3×IQR (ou outro critério) e recalcule os limites $Q1-k\times IQR$ e $Q3+k\times IQR$, conferindo se os outliers listados coincidem com os que ficam fora desses limites no Boxplot. Comente eventuais divergências.
  - Compare os times do grupo quanto à dispersão central (largura da faixa de 50% central): qual time é mais concentrado e qual é mais espalhado em cada variável? O padrão se mantém entre variáveis?

  - Apresente um quadro-resumo (linhas = variáveis, colunas = times, células = IQR) e comente os destaques, articulando com a assimetria e o CV já calculados.